PROYECTO INTEGRADOR FINAL

Análisis de ventas: qué vende, qué rinde y qué se devuelve

Curso de Data Analytics · Coderhouse

Alumno: Eduardo Timpanaro

Herramientas: SQL Server, Power Query, DAX y Power BI

Fecha: Noviembre de 2026

Cómo está organizado este documento

- Parte 1: las cuatro preguntas teóricas.
- Parte 2: el reporte de análisis, en siete secciones (contexto, dataset, EDA, modelo y SQL, limpieza, dashboard y conclusiones). Incluye los tres ejercicios prácticos.

Parte 1 · Preguntas teóricas

1. ¿Cuál es la diferencia entre datos e información y por qué importa para decidir?

Los datos son valores sueltos, sin contexto. Por ejemplo, en mi dataset una fila dice ORD104162 y 8838,83. Solo con eso no sé qué pasó. La información son esos datos ya procesados y puestos en contexto. Por ejemplo: las ventas netas de 2025 fueron 36,60 M, un 2,6% más que en 2024.

Es importante para decidir porque nadie decide mirando filas. Se decide con totales, comparaciones y tendencias. En este proyecto el ticket promedio da 4.818, pero la mediana es 3.463. Además, el 5,8% de los pedidos concentra el 22,5% de las ventas. Con esa información se ve que el promedio no representa a un pedido normal.

2. Sublenguajes de SQL y su función

Sublenguaje	Para qué sirve	Comandos	Ejemplo en este proyecto
DDL (definición)	Crear y modificar la estructura de la base	CREATE, ALTER, DROP	CREATE TABLE clientes, ventas, productos y geografia
DML (manipulación)	Cargar, cambiar o borrar datos	INSERT, UPDATE, DELETE	INSERT INTO clientes SELECT … para cargar desde ventas_raw
DQL (consulta)	Consultar datos. Algunos autores lo incluyen dentro de DML	SELECT	La consulta de ventas de los últimos 30 días
DCL (control)	Dar o quitar permisos	GRANT, REVOKE	No lo usé. Serviría para dar acceso de solo lectura a un analista
TCL (transacciones)	Confirmar o deshacer cambios	BEGIN TRANSACTION, COMMIT, ROLLBACK	No lo usé. Serviría para deshacer un UPDATE hecho por error

3. Cómo puede complementar la IA el análisis de datos en una empresa

La IA ayuda a hacer más rápido las tareas repetitivas. Por ejemplo, armar un borrador de una consulta SQL, revisar errores, documentar el trabajo o resumir resultados. Así el analista tiene más tiempo para lo importante: elegir qué preguntar, interpretar los resultados y responder por lo que presenta.

En este proyecto la usé como apoyo para revisar consultas y ordenar el trabajo. No tomé nada como bueno sin probarlo. Por ejemplo, ejecuté la consulta de los últimos 30 días y comprobé con un conteo aparte que daba 607 pedidos.

El riesgo es que la IA puede equivocarse con mucha seguridad. Puede inventar un número, usar una función que no existe en mi versión de SQL Server o sacar una conclusión que los datos no muestran. Por eso hay que validar cada resultado contra los datos originales.

4. Principios del storytelling con datos

- **Conocer a la audiencia.** Un informe para marketing no es igual a uno para finanzas. Cambia qué se muestra y con qué palabras.

- **Una idea por gráfico, con un título que diga la conclusión.** Por ejemplo, “Tecnología vende más, pero Office Supplies deja más ganancia” en vez de “Ventas por categoría”.
- **Estructura de historia.** Contexto, hallazgo y recomendación: de dónde partimos, qué encontramos y qué hacemos.
- **El gráfico correcto para cada dato.** Líneas para el tiempo y barras para comparar categorías.
- **Simplicidad.** Pocos elementos y el color con intención: resaltar lo importante y dejar el resto en gris.
- **Cerrar con una acción.** Un dato sin un “¿y ahora qué hacemos?” no ayuda a decidir.

Parte 2 · Reporte de análisis

1. Contexto del problema

Trabajo con los datos de una empresa de comercio minorista (ficticia, porque el dataset es sintético) que vende por tres canales (online, tienda física y marketplace) en cinco regiones. La gerencia quiere entender de dónde vienen sus ventas y su ganancia y, antes de tomar decisiones, saber si los indicadores con los que las mide son confiables.

Pregunta de negocio: ¿Cómo evolucionaron las ventas de la empresa en 2024 y 2025, qué categorías las sostienen y qué pasó en diciembre de 2025?

Para responderla busco contestar cuatro preguntas más chicas:

- ¿Cómo evolucionaron las ventas entre 2024 y 2025?
- ¿Qué categorías, canales y regiones aportan más ventas y más ganancia?
- ¿Qué pasó en diciembre de 2025 frente a noviembre y frente a diciembre de 2024?
- ¿Cuánto representan las devoluciones?
- ¿El ticket promedio es representativo, o lo inflan unos pocos pedidos muy grandes?

Indicadores (KPIs) que voy a seguir: ventas netas, ganancia y margen, cantidad de pedidos, ticket promedio (junto con la mediana) y tasa de devolución.

2. Descripción del dataset y fuentes

Usé el dataset público “Indian Retail Sales Analytics Dataset”, publicado en Kaggle por el usuario vigneshpgd. Según su descripción, es un dataset sintético de ventas minoristas, creado para prácticas de análisis y visualización de datos. Es un único archivo CSV (sales_data.csv) con 15.000 pedidos y 22 columnas, entre el 1/1/2024 y el 31/12/2025. Cada fila es un pedido (el Order_ID no se repite). Los importes están en rupias (INR).

Grupo	Columnas
Identificación	Order_ID, Customer_ID, Product_ID
Fecha	Order_Date
Ubicación y cliente	Region, City, Segment
Producto	Category, Subcategory
Venta	Channel, Quantity, Unit_Price_INR, Discount, Sales_INR, Discount_Amount_INR, Net_Sales_INR, Cost_INR, Profit_INR
Posventa y otros	Shipping_Days, Returned, Customer_Satisfaction, Payment_Method

Sales_INR es la venta bruta (cantidad por precio unitario), Net_Sales_INR es la bruta menos el descuento y Profit_INR es la ganancia (en los pedidos devueltos viene con un recorte, que explico en la sección 5). Como total de cada venta uso Net_Sales_INR.

Limitaciones que encontré al revisar el dataset

- No trae el nombre del cliente, solo un código (Customer_ID). Uso ese código como identificador.
- Un mismo cliente aparece con distintas regiones y segmentos según el pedido, y un mismo Product_ID aparece con distintos precios y categorías. Por eso no pude armar tablas de clientes y productos con esos atributos: la región y el segmento quedan en la tabla de ventas.

- Como el dataset es sintético, esos patrones son esperables: no vienen de un sistema real. Mis conclusiones valen como ejercicio de análisis, no como diagnóstico de una empresa concreta.

3. Análisis exploratorio de datos (EDA)

Calidad de los datos

Revisé el dataset antes de analizarlo: 15.000 filas, 15.000 pedidos únicos, 2.496 clientes, fechas completas entre 2024 y 2025, sin valores vacíos ni pedidos duplicados, y los importes cierran (la venta bruta es cantidad por precio, y la neta es la bruta menos el descuento). Hay una excepción, que explico en la sección 5: en los 1.095 pedidos devueltos la ganancia no es neto menos costo. Esta es la consulta de control y su resultado:

```sql
SELECT
  COUNT(*)                                  AS filas,
  COUNT(DISTINCT Order_ID)                  AS pedidos_distintos,
  COUNT(*) - COUNT(DISTINCT Order_ID)       AS duplicados,
  SUM(CASE WHEN Order_ID IS NULL OR Order_Date IS NULL OR Customer_ID IS NULL
           OR City IS NULL OR Net_Sales_INR IS NULL THEN 1 ELSE 0 END) AS filas_con_nulos,
  MIN(Order_Date)                           AS fecha_min,
  MAX(Order_Date)                           AS fecha_max,
  SUM(CASE WHEN Quantity <= 0 OR Unit_Price_INR <= 0 THEN 1 ELSE 0 END) AS cantidades_o_precios_invalidos,
  SUM(CASE WHEN ABS(Net_Sales_INR - (Sales_INR - Discount_Amount_INR)) > 0.05 THEN 1 ELSE 0 END) AS neto_incoherente,
  SUM(CASE WHEN ABS(Profit_INR - (Net_Sales_INR - Cost_INR)) > 0.05 THEN 1 ELSE 0 END) AS ganancia_incoherente
FROM dbo.ventas_raw;
```

Results | Messages

	filas	pedidos_distintos	duplicados	filas_con_nulos	fecha_min	fecha_max	cantidades_o_precios_invalidos	neto_incoherente	ganancia_incoherente
1	15000	15000	0	0	2024-01-01	2025-12-31	0	0	1095

Controles de calidad sobre la tabla original (ventas_raw) en SQL Server.

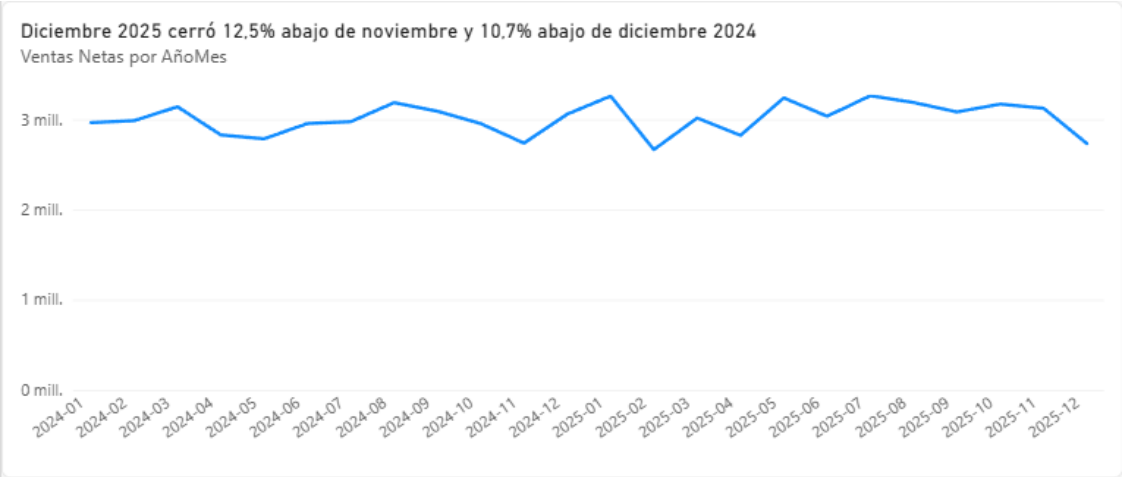
Resumen general

Indicador	Valor
Pedidos	15.000
Clientes únicos	2.496
Período	01/01/2024 al 31/12/2025
Ventas brutas (INR)	80,95 M
Descuentos (INR)	8,68 M (10,7% de las brutas)
Ventas netas (INR)	72,27 M
Costo (INR)	44,41 M
Ganancia (INR)	27,28 M (margen 37,7% sobre ventas netas)

Evolución anual

Año	Pedidos	Ventas netas (INR)	Ganancia (INR)	Ticket promedio
2024	7.440	35,67 M	13,45 M	4.794
2025	7.560	36,60 M	13,83 M	4.842
Variación 2025 vs 2024	**1,6%**	**2,6%**	**2,8%**	**1,0%**

Las ventas netas crecieron 2,6% entre 2024 y 2025, con un 1,6% más de pedidos y un ticket 1,0% más alto. Es un crecimiento chico y viene sobre todo del volumen. Mes a mes, las ventas se mueven entre 2,67 M (febrero de 2025) y 3,26 M (julio de 2025), sin una tendencia clara.



Ventas netas por mes en Power BI (eje desde cero).

Por categoría

Categoría	Pedidos	Ventas netas	% de ventas	Ganancia	Margen
Technology	4.231	20,49 M	28,4%	6,38 M	31,2%
Office Supplies	3.358	16,56 M	22,9%	6,96 M	42,0%
Furniture	2.859	13,65 M	18,9%	4,92 M	36,1%
Home & Kitchen	2.642	12,63 M	17,5%	4,82 M	38,2%
Beauty	1.910	8,94 M	12,4%	4,19 M	46,9%

Tecnología es la categoría que más vende (28,4%), pero tiene el margen más bajo (31,2%). Office Supplies vende menos y gana más: 6,96 M de ganancia contra 6,38 M de Tecnología. Beauty es la que menos vende, pero con el margen más alto (46,9%).

Por canal

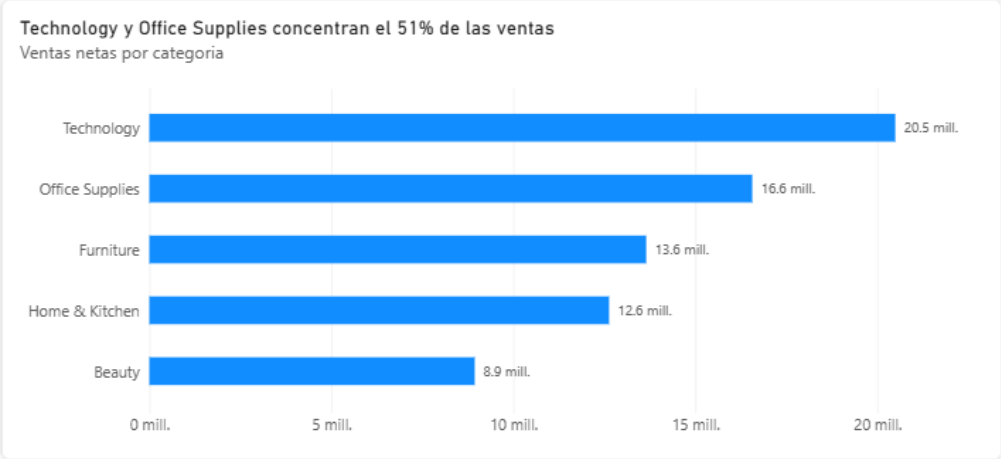
Canal	Pedidos	Ventas netas	% de ventas	Ganancia	Margen
Online	8.700	41,72 M	57,7%	15,73 M	37,7%
Retail Store	3.319	15,77 M	21,8%	5,94 M	37,7%
Marketplace	2.981	14,79 M	20,5%	5,60 M	37,9%

Online concentra más de la mitad de las ventas (57,7%). Los tres canales tienen prácticamente el mismo margen (entre 37,7% y 37,9%).

Por región

Región	Pedidos	Ventas netas	% de ventas	Ganancia	Margen
South	3.561	17,18 M	23,8%	6,46 M	37,6%
West	3.314	15,95 M	22,1%	6,02 M	37,7%
North	3.217	15,57 M	21,5%	5,90 M	37,9%
Central	2.489	11,97 M	16,6%	4,53 M	37,9%
East	2.419	11,60 M	16,0%	4,37 M	37,7%

South lidera con el 23,8% de las ventas, y East y Central quedan últimas (16,0% y 16,6%). El ticket y el margen son parecidos en las cinco regiones, así que la diferencia está en la cantidad de pedidos y no en el precio.



Ventas netas por categoría en el dashboard de Power BI. Canal y región se pueden ver con las segmentaciones.

Devoluciones

Se devolvieron 1.095 pedidos, el 7,3% del total. Equivalen a 5,39 M en ventas netas (7,5%). La tasa es parecida en todos los canales y categorías (entre 6,7% y 7,9%), así que no hay un foco puntual. La ganancia de esos pedidos viene con un recorte en el dataset (ver sección 5).

Distribución del importe por pedido y valores atípicos

Medida (ventas netas por pedido, INR)	Valor
Media (ticket promedio)	4.818
Mediana	3.463
Diferencia media − mediana	1.356 (39% más)
Q1 / Q3	1.793 / 6.230
IQR	4.437
Límite superior (Q3 + 1,5 × IQR)	12.886
Límite inferior (Q1 − 1,5 × IQR)	-4.862 (negativo: no hay valores bajos atípicos)
Pedidos atípicos (por encima del límite superior)	875 (5,8% de los pedidos)
Ventas netas que concentran	16,23 M (22,5% del total)
Pedido más grande	117.281

La media está un 39% por encima de la mediana: unos pocos pedidos muy grandes tiran el promedio hacia arriba. Con el método IQR hay 875 pedidos atípicos (5,8% del total) que concentran el 22,5% de las ventas netas. No son errores de carga: en todos los casos el importe coincide con cantidad por precio, y son pedidos grandes legítimos. Conclusión: el ticket promedio de 4.818 no representa a un pedido típico, y conviene mostrar la mediana (3.463) junto al promedio. Estas son las consultas con sus resultados:

```sql
WITH q AS (
  SELECT DISTINCT
    AVG(ventas_netas)                                          OVER () AS media,
    PERCENTILE_CONT(0.5)  WITHIN GROUP (ORDER BY ventas_netas) OVER () AS mediana,
    PERCENTILE_CONT(0.25) WITHIN GROUP (ORDER BY ventas_netas) OVER () AS q1,
    PERCENTILE_CONT(0.75) WITHIN GROUP (ORDER BY ventas_netas) OVER () AS q3
  FROM ventas
)
SELECT media, mediana, q1, q3,
       q3 - q1                  AS iqr,
       q1 - 1.5 * (q3 - q1)     AS limite_inferior,
       q3 + 1.5 * (q3 - q1)     AS limite_superior
FROM q;
```

	media	mediana	q1	q3	iqr	limite_inferior	limite_superior
1	4818.100912	3462.51	1793.36	6230.4825	4437.1225	-4862.32375	12886.16625

Media, mediana, cuartiles, IQR y límites, calculados en SQL Server.

```sql
WITH q AS (
  SELECT DISTINCT
    PERCENTILE_CONT(0.25) WITHIN GROUP (ORDER BY ventas_netas) OVER () AS q1,
    PERCENTILE_CONT(0.75) WITHIN GROUP (ORDER BY ventas_netas) OVER () AS q3
  FROM ventas
)
SELECT COUNT(*)            AS ventas_atipicas,
       SUM(v.ventas_netas) AS monto_atipicas,
       SUM(v.ventas_netas) * 100.0 / (SELECT SUM(ventas_netas) FROM ventas) AS pct_del_total
FROM ventas v CROSS JOIN q
WHERE v.ventas_netas > q.q3 + 1.5 * (q.q3 - q.q1);
```

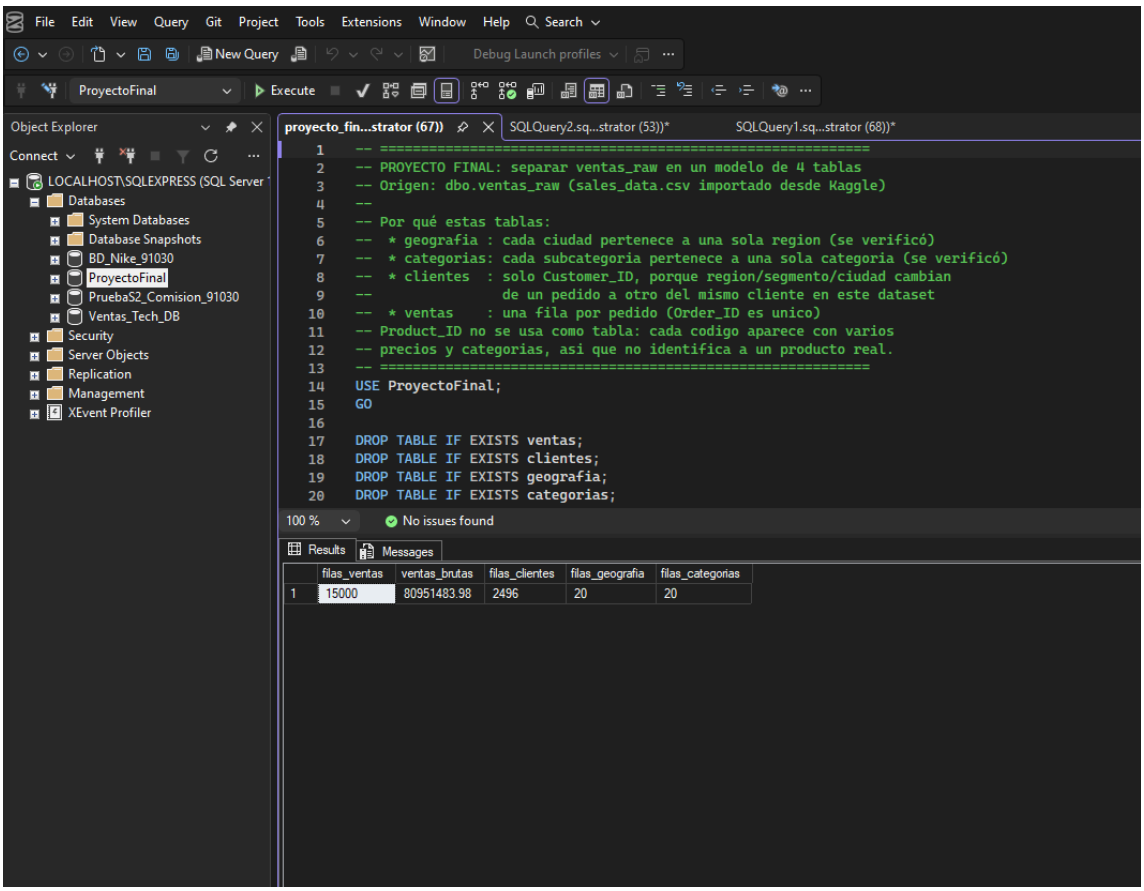
	ventas_atipicas	monto_atipicas	pct_del_total
1	875	16232399.19	22.460300

Cantidad de pedidos atípicos, monto que suman y porcentaje del total.

4. Modelo de datos y consultas SQL

Importación y separación en tablas

Importé el CSV a SQL Server como una tabla de partida (ventas_raw) y, como el dataset viene en una sola tabla, la separé en cuatro con INSERT … SELECT DISTINCT: ventas, clientes, geografia y productos, con sus claves primarias y foráneas. Después comprobé que no se perdió ni se duplicó nada.



Control tras separar las tablas: 15.000 ventas, 2.496 clientes, 20 ciudades y 20 tipos de producto.

Ejercicio 2 · Diagrama entidad-relación

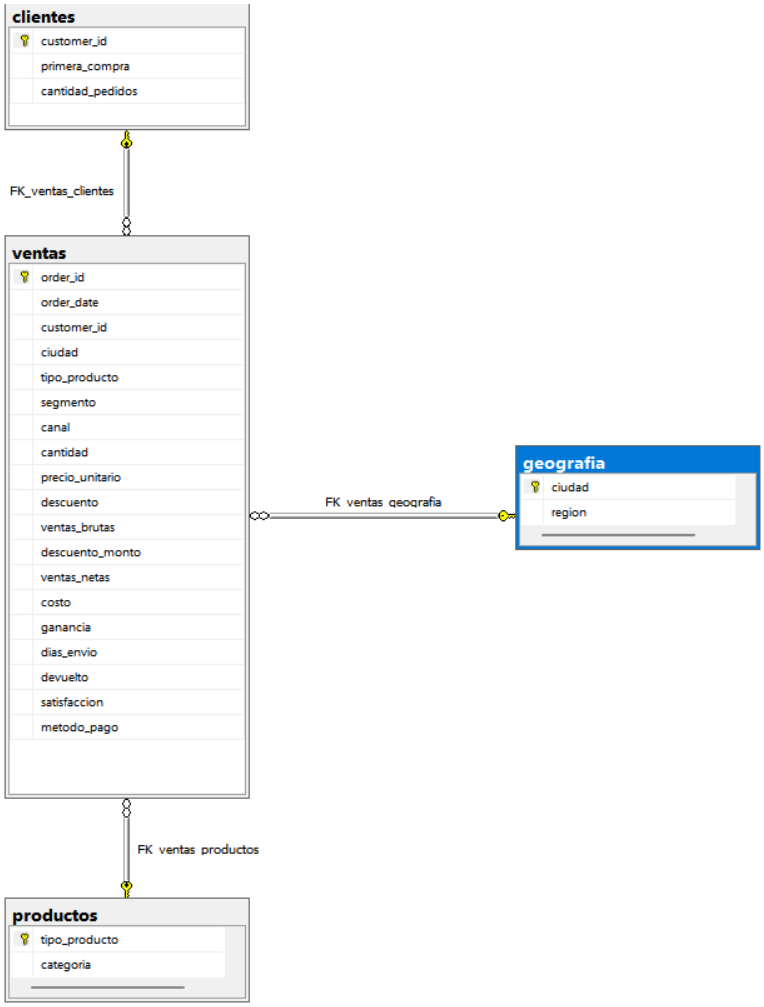


Diagrama ER de la base ProyectoFinal, generado en SQL Server Management Studio.

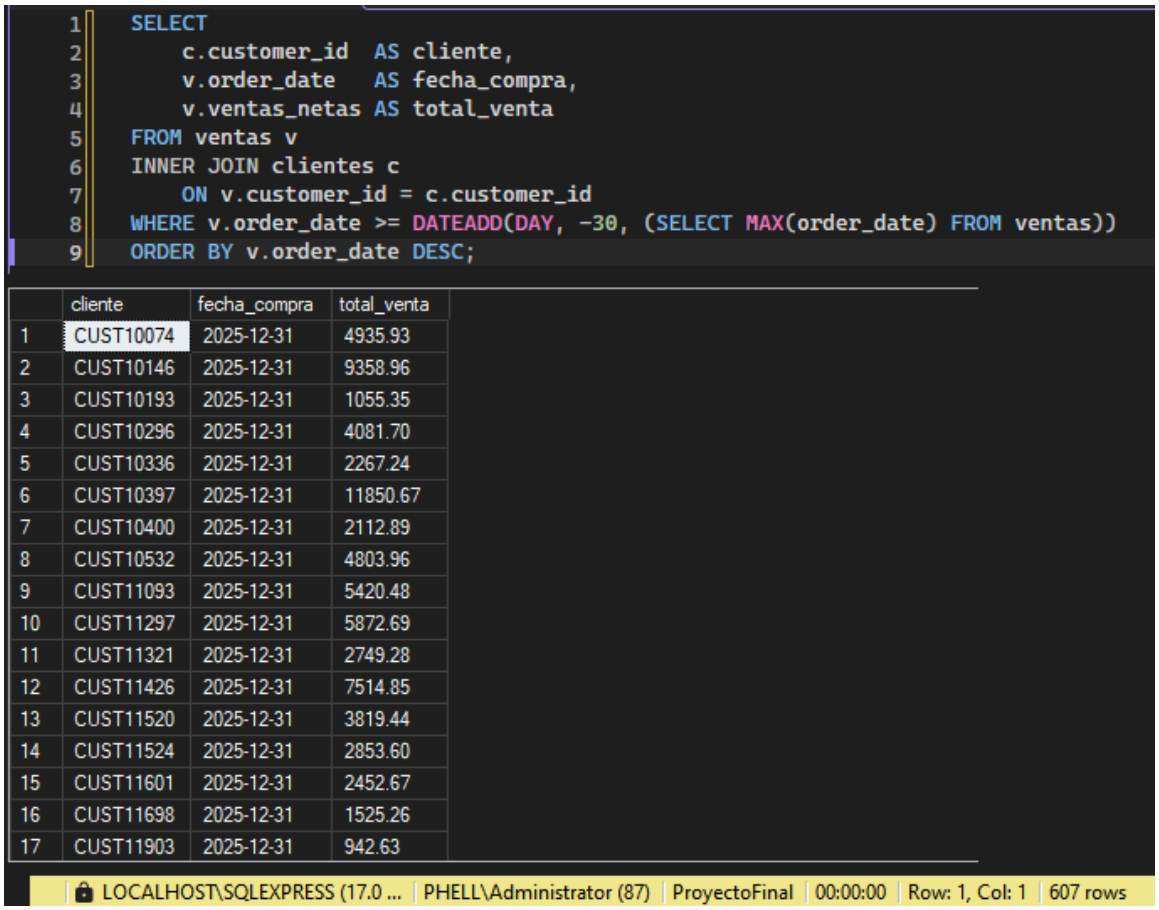
Entidad	Qué representa	Clave	Relación
clientes	Quién compra: código de cliente, fecha de primera compra y cantidad de pedidos	customer_id	1 cliente : N ventas
productos	Tipo de producto (por ejemplo Laptops, Chairs o Makeup) y su categoría	tipo_producto	1 producto : N ventas
geografia	Ciudad y región a la que pertenece	ciudad	1 ciudad : N ventas
ventas	Un pedido por fila, con fecha, canal, importes y devolución	order_id	Lado “N” de las tres relaciones

Un cliente puede hacer muchas ventas, pero cada venta pertenece a un solo cliente (1:N). Lo mismo pasa con el tipo de producto y con la ciudad. Cada fila de productos es un tipo de producto y no un artículo individual, porque el Product_ID del dataset aparece con precios y categorías distintos y no identifica un producto real.

Ejercicio 1 · Consulta SQL: ventas de los últimos 30 días

Preparación: la fecha (Order_Date) quedó como tipo DATE para poder filtrar por rango, y conservé las columnas que pide la consigna: identificador del cliente, fecha de compra y total de la venta. Los últimos 30 días se cuentan desde la fecha de la última venta del dataset (31/12/2025) y no desde la fecha de hoy.

```sql
SELECT
    c.customer_id  AS cliente,
    v.order_date   AS fecha_compra,
    v.ventas_netas AS total_venta
FROM ventas v
INNER JOIN clientes c
    ON v.customer_id = c.customer_id
WHERE v.order_date >= DATEADD(DAY, -30, (SELECT MAX(order_date) FROM ventas))
ORDER BY v.order_date DESC;
```



	cliente	fecha_compra	total_venta
1	CUST10074	2025-12-31	4935.93
2	CUST10146	2025-12-31	9358.96
3	CUST10193	2025-12-31	1055.35
4	CUST10296	2025-12-31	4081.70
5	CUST10336	2025-12-31	2267.24
6	CUST10397	2025-12-31	11850.67
7	CUST10400	2025-12-31	2112.89
8	CUST10532	2025-12-31	4803.96
9	CUST11093	2025-12-31	5420.48
10	CUST11297	2025-12-31	5872.69
11	CUST11321	2025-12-31	2749.28
12	CUST11426	2025-12-31	7514.85
13	CUST11520	2025-12-31	3819.44
14	CUST11524	2025-12-31	2853.60
15	CUST11601	2025-12-31	2452.67
16	CUST11698	2025-12-31	1525.26
17	CUST11903	2025-12-31	942.63

Resultado de la consulta en SQL Server: 607 filas, ordenadas de la compra más nueva (31/12/2025) a la más vieja.

```sql
SELECT COUNT(*) AS ventas_ultimos_30_dias
FROM ventas
WHERE order_date >= DATEADD(DAY, -30, (SELECT MAX(order_date) FROM ventas));
```

	ventas_ultimos_30_dias
1	607

Conteo de las ventas de los últimos 30 días: 607.

Qué usé y por qué: la tabla clientes aporta el identificador del cliente y la tabla ventas aporta la fecha y el total. Las uní con un INNER JOIN por customer_id, así que solo aparecen ventas con cliente. Como total usé ventas_netas (la venta con el descuento ya aplicado). El filtro toma MAX(order_date) para que el rango se calcule a partir de los datos y no de la fecha de la computadora, y el ORDER BY … DESC deja primero la compra más reciente. Como el rango incluye el 1/12/2025, cubre 31 días de calendario y devuelve 607 pedidos.

5. Transformación y limpieza (Power Query)

Controles en SQL antes de transformar

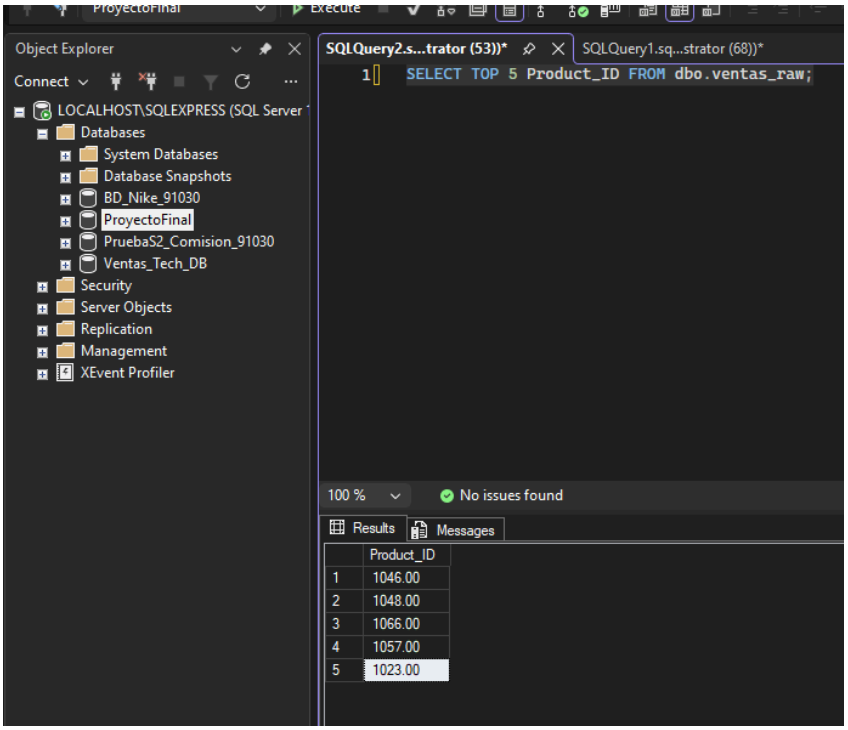
Antes de pasar los datos a Power BI hice un control de calidad sobre la tabla original (ventas_raw): filas, pedidos duplicados, valores vacíos, rango de fechas, cantidades o precios inválidos y que los importes sean coherentes. El resultado está en la captura de la sección 3.

```
SELECT
  COUNT(*)                              AS filas,
  COUNT(DISTINCT Order_ID)              AS pedidos_distintos,
  COUNT(*) - COUNT(DISTINCT Order_ID) AS duplicados,
  SUM(CASE WHEN Order_ID IS NULL OR Order_Date IS NULL OR Customer_ID IS NULL
           OR City IS NULL OR Net_Sales_INR IS NULL THEN 1 ELSE 0 END) AS filas_con_nulos,
  MIN(Order_Date) AS fecha_min,  MAX(Order_Date) AS fecha_max,
  SUM(CASE WHEN Quantity <= 0 OR Unit_Price_INR <= 0 THEN 1 ELSE 0 END) AS
cantidades_o_precios_invalidos,
  SUM(CASE WHEN ABS(Net_Sales_INR - (Sales_INR - Discount_Amount_INR)) > 0.05
           THEN 1 ELSE 0 END) AS neto_incoherente,
  SUM(CASE WHEN ABS(Profit_INR - (Net_Sales_INR - Cost_INR)) > 0.05
           THEN 1 ELSE 0 END) AS ganancia_incoherente
FROM dbo.ventas_raw;
```

Resultado: 15.000 filas y 15.000 pedidos distintos, 0 duplicados, 0 filas con valores vacíos, fechas del 1/1/2024 al 31/12/2025, y 0 cantidades o precios inválidos. El neto cierra en todas las filas. La excepción es la ganancia: 1.095 filas no cierran, y coinciden justo con la cantidad de pedidos devueltos. Lo investigué más abajo.

Un problema real: el tipo de dato de Product_ID

Al importar el CSV, el asistente de SQL Server adivinó mal el tipo de la columna Product_ID: la guardó como dinero (money) y convirtió códigos como P1046 en 1046,00, perdiendo la letra P. Lo detecté al consultar las primeras filas. Borré la tabla y la importé de nuevo forzando el tipo nvarchar(50) para esa columna, y verifiqué que los códigos quedaran completos.



Antes: Product_ID importado como número (1046.00) en lugar del código P1046.

```
SELECT TOP 10 Product_ID, Unit_Price_INR FROM dbo.ventas_raw;
```

	Product_ID	Unit_Price_INR
1	P1046	327.149993896484
2	P1048	1711.98999023438
3	P1066	1180.94995117188
4	P1057	703.239990234375
5	P1023	380.549987792969
6	P1032	887.059997558594
7	P1082	2275.3798828125
8	P1031	957.150024414063
9	P1046	670.950012207031
10	P1071	2589.8798828125

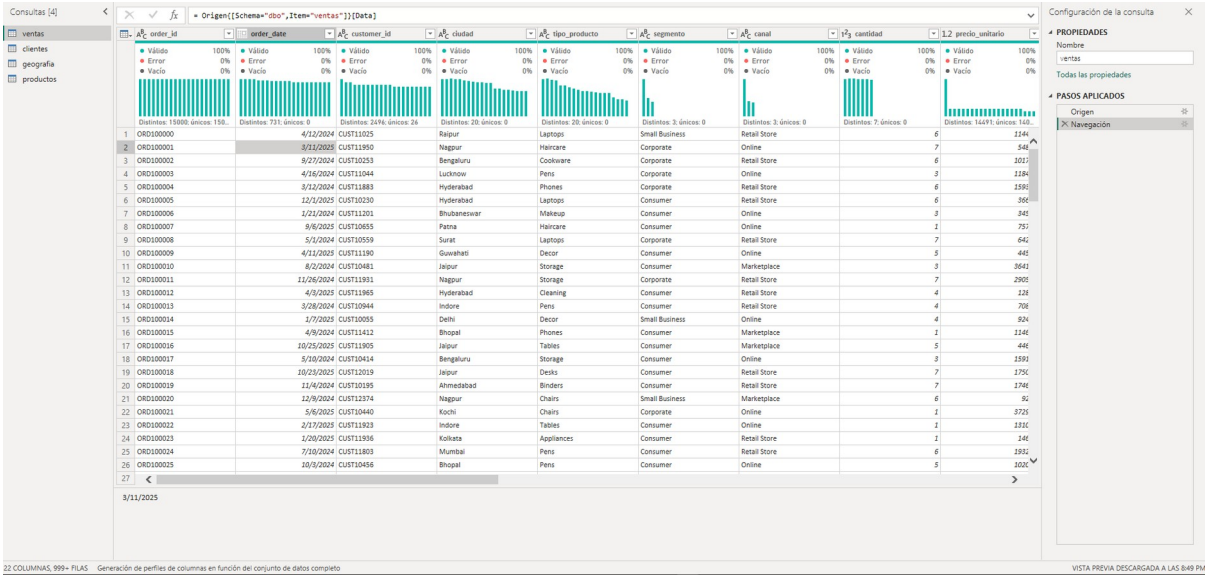
Después: Product_ID con los códigos completos (P1046, P1048…). El precio unitario viene con muchos decimales en la tabla original; al armar la tabla de ventas lo convertí a 2 decimales.

Transformaciones en Power Query

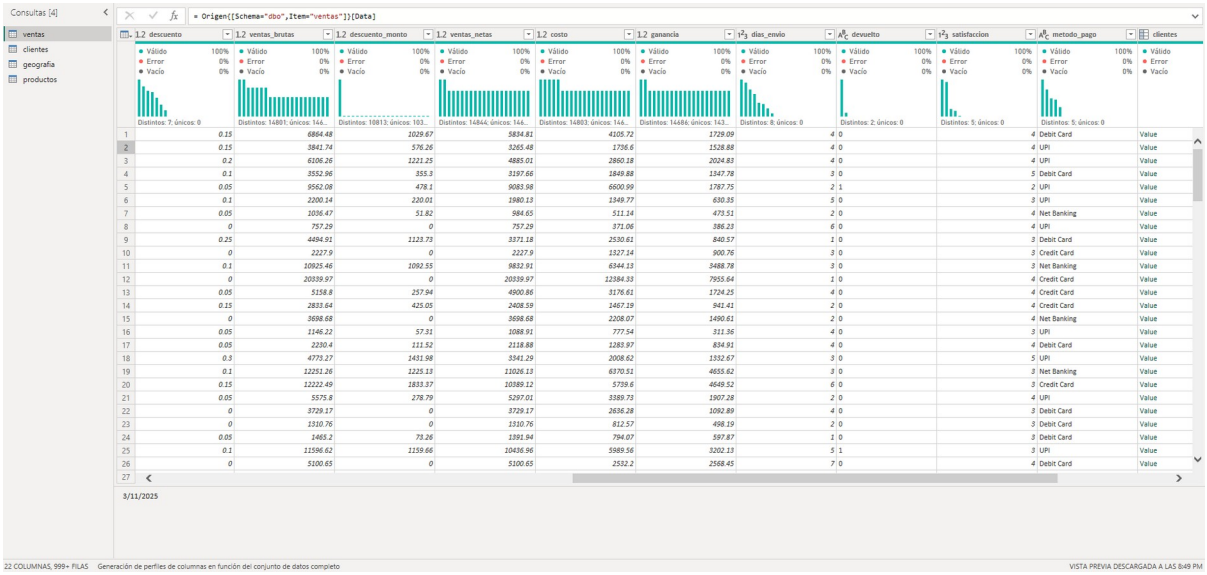
Conecté Power BI a la base ProyectoFinal en modo Importar con las cuatro tablas (ventas, clientes, geografia y productos) y entré con “Transformar datos”, sin cargar todavía. En Power Query revisé y dejé estos tipos:

- Fechas (order_date, primera_compra): tipo Fecha.
- Importes (ventas_brutas, ventas_netas, costo, ganancia, descuento_monto, precio_unitario): Número decimal.
- Cantidades (cantidad, dias_envio, cantidad_pedidos, satisfaccion): Número entero.
- devuelto: venía como texto (0 o 1) y la cambié a Número entero, para poder sumarla y calcular la tasa de devolución. Es la transformación que aparece como “Tipo cambiado” en los pasos aplicados.
- Textos (códigos, canal, segmento, categoría, región): Texto.

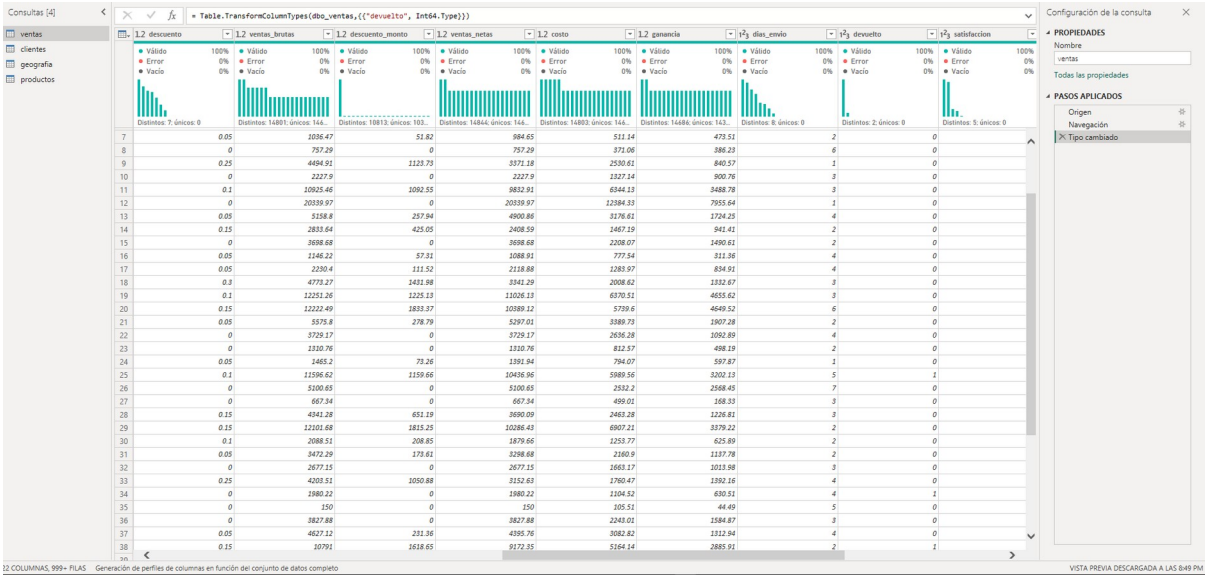
Activé el perfil de columnas sobre todo el conjunto de datos (por defecto Power Query solo analiza las primeras 1.000 filas). Con eso se ve que no hay errores ni valores vacíos en ninguna columna, que order_id tiene 15.000 valores distintos y que customer_id tiene 2.496.



Power Query: tabla ventas, columnas de identificación, con el perfil sobre todo el conjunto de datos.



Power Query: columnas de importes y de posventa, con 0% de errores y de vacíos.



Pasos aplicados: Origen, Navegación y Tipo cambiado (devuelto a número entero).

Las devoluciones y la ganancia: lo que encontré y cómo lo trato

El control de la sección 3 mostró que la ganancia de 1.095 pedidos no cerraba. Para entender qué pasaba comparé, según el pedido haya sido devuelto o no, la ganancia que trae el dataset con la que debería dar (ventas netas menos costo):

```sql
SELECT devuelto,
       COUNT(*)                        AS pedidos,
       SUM(ventas_netas)               AS ventas_netas,
       SUM(ventas_netas - costo)       AS ganancia_esperada,
       SUM(ganancia)                   AS ganancia_en_dataset
FROM ventas
GROUP BY devuelto;
```

	devuelto	pedidos	ventas_netas	ganancia_esperada	ganancia_en_dataset
1	1	1095	5393145.55	2087923.93	1503305.34
2	0	13905	66878368.13	25775262.68	25775262.16

Ganancia esperada contra ganancia del dataset, según el pedido haya sido devuelto (1) o no (0).

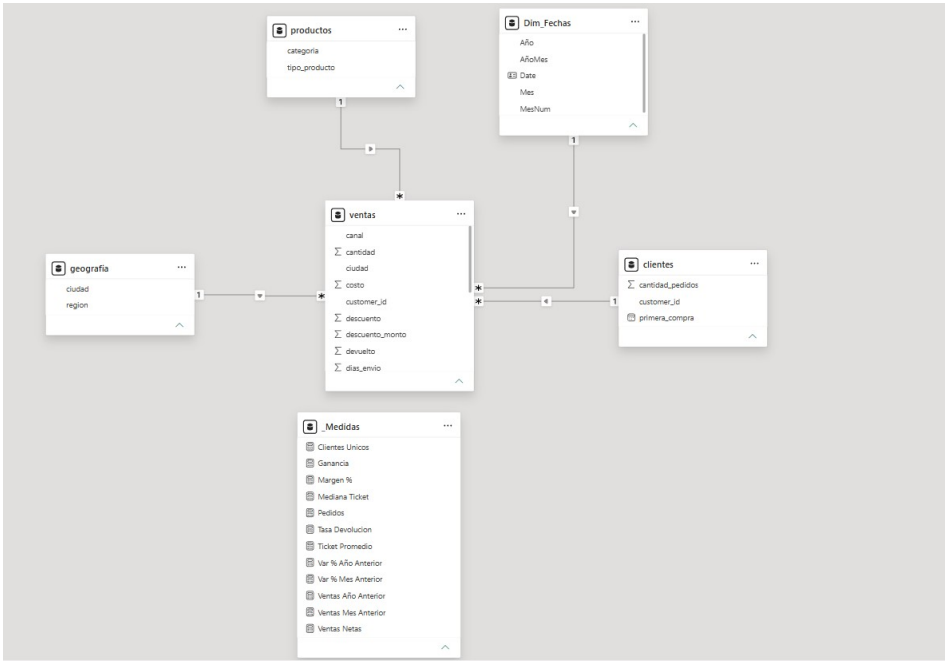
En los pedidos no devueltos la ganancia coincide. En los devueltos, la ganancia del dataset es el 72% de la esperada (1,50 M contra 2,09 M). Es decir, el dataset aplica un recorte fijo a la ganancia

de los pedidos devueltos. No sé por qué eligió ese valor: el dataset es sintético y no trae documentación de esa regla.

Decisión: dejé las cifras tal como vienen en el dataset, sin recalcular ni excluir nada, y lo aclaro acá para que se lea con el contexto correcto. Eso significa dos cosas: (1) las ventas netas de 72,27 M incluyen 5,39 M de pedidos devueltos (7,5%); sin ellos serían 66,88 M. (2) La ganancia de 27,28 M y el margen de 37,7% ya tienen el recorte; si la ganancia se calculara como ventas netas menos costo en todos los pedidos, daría 27,86 M y un margen de 38,6%. La diferencia es de 0,58 M (2,1%) y no cambia ninguna de las conclusiones. La tasa de devolución (7,3%) queda como indicador aparte.

Modelo en estrella y medidas DAX

En Power BI relacioné ventas con clientes, productos y geografia (uno a muchos, filtro en una sola dirección) y creé una tabla calendario (Dim_Fechas) marcada como tabla de fechas, relacionada con order_date. Las medidas están en una tabla aparte llamada _Medidas.



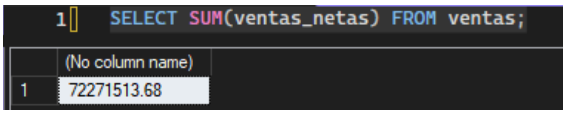
Vista de modelo en Power BI: ventas en el centro, con sus tres dimensiones y el calendario, más la tabla _Medidas.

```
Ventas Netas = SUM(ventas[ventas_netas])
Ganancia = SUM(ventas[ganancia])
Margen % = DIVIDE([Ganancia], [Ventas Netas])
Pedidos = DISTINCTCOUNT(ventas[order_id])
Clientes Unicos = DISTINCTCOUNT(ventas[customer_id])
Ticket Promedio = DIVIDE([Ventas Netas], [Pedidos])
Mediana Ticket = MEDIAN(ventas[ventas_netas])
Tasa Devolucion = DIVIDE(SUM(ventas[devuelto]), COUNTROWS(ventas))
Ventas Año Anterior = CALCULATE([Ventas Netas], SAMEPERIODLASTYEAR(Dim_Fechas[Date]))
Var % Año Anterior = VAR _ant = [Ventas Año Anterior]
                     RETURN DIVIDE([Ventas Netas] - _ant, _ant)
Ventas Mes Anterior = CALCULATE([Ventas Netas], DATEADD(Dim_Fechas[Date], -1, MONTH))
Var % Mes Anterior = VAR _ant = [Ventas Mes Anterior]
                     RETURN DIVIDE([Ventas Netas] - _ant, _ant)
```

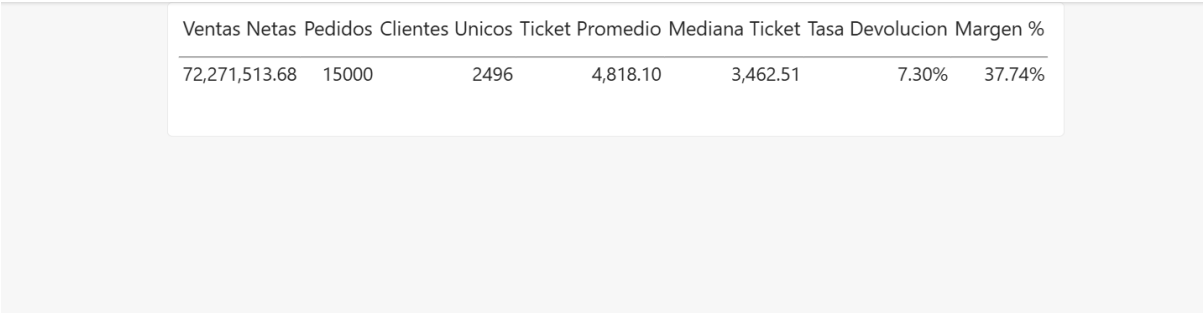


Una de las medidas en Power BI (Var % Mes Anterior), con formato de porcentaje.

Validación contra SQL. Antes de armar el dashboard comprobé que Power BI da los mismos números que SQL Server. La suma de ventas netas en SQL es 72.271.513,68 y la medida Ventas Netas de Power BI da exactamente lo mismo, y los pedidos (15.000) y los clientes únicos (2.496) también coinciden con las consultas de control.



SQL Server: suma de ventas netas.



Power BI: las siete medidas principales calculadas sobre todo el dataset.

Validación estadística de los KPIs

Para comprobar que el ticket promedio es confiable calculé la media y la mediana de ventas_netas y detecté valores atípicos con el método IQR. Los resultados y las capturas están en la sección 3. Estas son las consultas:

```
-- Media, mediana, cuartiles y límites del IQR
WITH q AS (
  SELECT DISTINCT
    AVG(ventas_netas) OVER () AS media,
    PERCENTILE_CONT(0.5)  WITHIN GROUP (ORDER BY ventas_netas) OVER () AS mediana,
    PERCENTILE_CONT(0.25) WITHIN GROUP (ORDER BY ventas_netas) OVER () AS q1,
    PERCENTILE_CONT(0.75) WITHIN GROUP (ORDER BY ventas_netas) OVER () AS q3
  FROM ventas
)
SELECT media, mediana, q1, q3, q3 - q1 AS iqr,
       q1 - 1.5 * (q3 - q1) AS limite_inferior,
       q3 + 1.5 * (q3 - q1) AS limite_superior
FROM q;

-- Pedidos atípicos, cuánto suman y qué porcentaje del total
WITH q AS (
  SELECT DISTINCT
    PERCENTILE_CONT(0.25) WITHIN GROUP (ORDER BY ventas_netas) OVER () AS q1,
    PERCENTILE_CONT(0.75) WITHIN GROUP (ORDER BY ventas_netas) OVER () AS q3
  FROM ventas
)
SELECT COUNT(*) AS ventas_atipicas,
       SUM(v.ventas_netas) AS monto_atipicas,
       SUM(v.ventas_netas) * 100.0 / (SELECT SUM(ventas_netas) FROM ventas) AS pct_del_total
FROM ventas v CROSS JOIN q
WHERE v.ventas_netas > q.q3 + 1.5 * (q.q3 - q.q1);
```

6. Dashboard y visualizaciones (Power BI)

El dashboard tiene lectura en Z: arriba el título y los filtros, después los indicadores, y abajo un gráfico de tendencia a la izquierda, uno de comparación a la derecha y una tabla de detalle. Arriba van los resúmenes para decidir rápido, y abajo el detalle para quien quiere investigar. El título de la página es la pregunta de negocio: “¿Dónde estamos y qué pasó en diciembre?”.

Zona	Visual	Título del visual
Arriba	Segmentaciones por año, canal y región	—
Debajo de los filtros	5 tarjetas: ventas netas, ganancia, ticket promedio, mediana del ticket y tasa de devolución	—
Medio izquierda	Líneas: ventas netas por mes	Diciembre 2025 cerró 12,5% abajo de noviembre y 10,7% abajo de diciembre 2024
Medio derecha	Barras: ventas netas por categoría	Technology y Office Supplies concentran el 51% de las ventas
Abajo	Tabla por mes: ventas netas, pedidos y variación contra el mes y el año anterior	—

Dos decisiones de diseño. Primero, las tarjetas de ticket promedio (4,82 mil) y mediana (3,46 mil) están una al lado de la otra, porque la validación estadística mostró que el promedio está inflado por pedidos grandes. Segundo, el gráfico de líneas arranca en cero: con un eje que empieza en 2,6 M, una variación de 10% parecería una caída enorme. La tabla de abajo respalda el título del gráfico: la fila 2025-12 muestra -12,53% contra noviembre y -10,66% contra diciembre de 2024.

Una aclaración: los títulos de los gráficos están escritos a mano, así que describen la vista completa, sin filtros. Con otro filtro activo, los porcentajes pueden ser distintos.



Dashboard completo en Power BI, sin filtros.

Para mostrar que los filtros funcionan, esta es la misma página con el año 2025 seleccionado. Cambian las tarjetas (ventas netas de 36,60 M), el gráfico de líneas, las barras y la tabla.



El mismo dashboard con el filtro Año = 2025.

Ejercicio 3 · Informe mensual de ventas para el equipo de marketing

Gráficos que usaría. Tarjetas con los indicadores del mes y su variación contra el mes anterior y contra el mismo mes del año anterior. Un gráfico de líneas con los últimos 12 a 24 meses y el mes actual resaltado, para ver si lo que pasó es una tendencia o un movimiento normal. Barras por categoría y por canal, para ver qué empujó o frenó el resultado. Y, si hace falta, una tabla de detalle.

Cómo armaría la narrativa, en cuatro pasos.

1. Cómo cerró el mes: los indicadores principales, con su comparación.
2. Qué cambió y por qué le importa a marketing: qué categorías y canales explican el resultado.
3. Qué recomiendo hacer: una acción concreta, no solo el dato.
4. Qué voy a mirar el mes que viene: para saber si el cambio se confirma.

Ejemplo con diciembre de 2025. Las ventas netas fueron de 2,73 M: 12,5% menos que en noviembre y 10,7% menos que en diciembre de 2024, y el segundo mes más bajo de 2025 (después de febrero). Título del gráfico: “Diciembre cerró 10,7% abajo del año anterior, pero dentro del rango normal del año”. Ese “pero” es importante: en esta serie las variaciones de alrededor de 10% son habituales (febrero de 2025 también cayó 10,7% contra febrero de 2024). Además, noviembre de 2025 había estado 14,1% arriba de noviembre de 2024, así que la caída de diciembre es un quiebre puntual y no una tendencia. Por eso la recomendación para marketing no sería reaccionar a un solo mes, sino ver si la caída se repite en los próximos dos o tres.

7. Conclusiones e insights

Separo lo que muestran los datos (dato) de lo que sugiero hacer (recomendación). Cuando algo es una hipótesis, lo digo.

1. Las ventas son estables, con un crecimiento chico

Dato: Las ventas netas subieron 2,6% (de 35,67 M a 36,60 M). Los pedidos subieron 1,6% y el ticket 1,0%. Mes a mes se mueven alrededor de ±10%, sin una tendencia clara.

Recomendación: Si se quiere crecer hace falta una acción nueva, por ejemplo conseguir más clientes o más pedidos. Con el ritmo actual no alcanza. Tampoco conviene reaccionar a un solo mes bajo.

2. Tecnología vende más, pero no es la que más gana

Dato: Tecnología aporta el 28,4% de las ventas netas, pero tiene el margen más bajo (31,2%). Office Supplies vende menos (22,9%) pero gana más: 6,96 M contra 6,38 M, con 42,0% de margen. Beauty tiene el mejor margen (46,9%) y la menor venta.

Recomendación: Revisar los costos y descuentos de Tecnología antes de seguir promocionándola, y probar promociones en Office Supplies y Beauty. Por qué el margen es bajo es una hipótesis: con estos datos no se sabe si es por costo o por descuento.

3. Online concentra más de la mitad de las ventas

Dato: Online aporta el 57,7% de las ventas netas. Los tres canales tienen casi el mismo margen (37,7% a 37,9%). Marketplace tiene el ticket más alto (4.961, contra 4.795 de Online y 4.750 de tienda).

Recomendación: Online es la base del negocio, pero depender de un solo canal es un riesgo. Como el margen es igual en todos, crecer en Marketplace no baja la rentabilidad.

4. Las regiones se diferencian por volumen, no por precio

Dato: South aporta el 23,8% de las ventas, y Central y East el 16,6% y el 16,0%. El ticket (4.794 a 4.841) y el margen (37,6% a 37,9%) son casi iguales en las cinco regiones. La diferencia está en la cantidad de pedidos: 3.561 en South y 2.419 en East.

Recomendación: En East y Central conviene buscar más pedidos y no cambiar precios.

5. Las devoluciones son un nivel general, no un foco

Dato: Se devolvió el 7,3% de los pedidos (1.095), que suman 5,39 M (7,5% de las ventas netas). La tasa es parecida en todos los canales y categorías (6,7% a 7,9%).

Recomendación: Como no hay un canal o categoría que se destaque, conviene seguir la tasa general y buscar causas comunes. Con este dataset no se ve el motivo de cada devolución.

6. El ticket promedio no representa a un pedido típico

Dato: La media es 4.818 y la mediana 3.463. Los 875 pedidos que pasan los 12.886 (5,8% del total) concentran el 22,5% de las ventas netas. No son errores: el importe coincide con cantidad por precio.

Recomendación: Mostrar siempre la mediana junto al promedio, y analizar aparte los pedidos grandes para saber quiénes son y cómo retenerlos.

7. Diciembre de 2025 cerró más bajo, pero es un solo mes

Dato: Las ventas netas de diciembre fueron 2,73 M: 12,5% menos que noviembre y 10,7% menos que diciembre de 2024. Noviembre de 2025 había subido 14,1% contra noviembre de 2024, y febrero de 2025 también cayó 10,7% contra febrero de 2024.

Recomendación: No tomar una acción grande por un solo mes. Mirar enero y febrero de 2026 para ver si se repite. Con estos datos no se puede explicar la causa. Cualquier explicación (estacionalidad, campaña, canal) sería una hipótesis.

Limitaciones

- Son solo dos años de datos, así que no se puede medir estacionalidad con confianza.
- Las devoluciones están incluidas en las ventas netas, y la ganancia de los pedidos devueltos viene con un recorte del 28% en el dataset (explicado en la sección 5). Si se corrigiera, el margen pasaría de 37,7% a 38,6%.
- Los atributos de cliente y producto del dataset no son estables, por eso no hice análisis por cliente ni por segmento de cliente.

- El dataset es sintético (así lo indica su descripción en Kaggle), así que las conclusiones son un ejercicio de análisis y no un diagnóstico de una empresa real.

En resumen, el negocio es estable y rentable (margen de 37,7%), pero crece poco. Las mejores oportunidades que muestran los datos son revisar la rentabilidad de Tecnología, sumar pedidos en las regiones más chicas y mirar los indicadores con la mediana y no solo con el promedio.